



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 2

Validación, Simulación y Métodos de Remuestreo

Informe técnico grupal 20%

Título del proyecto: Modelamiento Estadístico e Inferencia para la Detección Temprana de la Enfermedad Renal Crónica en Pacientes de la India.

Integrantes: Treici Medina Lizama

Dataset: Dataset 2: Chronic Kidney Disease

Docente: JEAN PAUL MAIDANA GONZALEZ

Fecha: 08/07/2026

Repositorio GitHub: <https://github.com/treicimedina/Enfermedad-Renal>

Información de la evaluación

Fase del proyecto: Fase 3: Desarrollo del proyecto

Modalidad: Grupal Ponderación: 20 % de la nota final

Entregables: Informe PDF (máx. 7 págs.) Notebook . ipynb Repositorio GitHub (carpetas S1, S2 y archivo de resultados validados)

Resultado de aprendizaje (RA2): implementar métodos computacionales de simulación y remuestreo para apoyar la toma de decisiones en escenarios complejos.

Indicadores: ID2.1, ID2.2, ID2.3.

Prerrequisito: Sumativa 1 completada (usarán sus resultados).

Conexión con evaluaciones anteriores

Esta evaluación no es independiente: todo el trabajo debe construirse explícitamente sobre los resultados de la Sumativa 1 (parámetros estimados, intervalos de confianza, pruebas de hipótesis y correlaciones). Si no se utilizan resultados propios de S1, la evaluación no podrá alcanzar la calificación máxima.

Índice

1	Validación de resultados de S1 mediante bootstrap	2
2	Validación de pruebas de hipótesis mediante permutación	3
3	Evaluación de estabilidad de correlaciones	4
4	Simulación Monte Carlo basada en parámetros de S1	4
5	Análisis de robustez	6
6	Preparación para la Sumativa 3	6
7	Bibliografía (APA 7)	7

1. Validación de resultados de S1 mediante Bootstrap:

Para validar las estimaciones puntuales de la Sumativa 1 (S1), se ejecutó un procedimiento de bootstrap no paramétrico con $B = 10,000$ remuestras sobre la media de tres variables clínicas fundamentales: **Edad (age)**, **Presión Arterial (bp)** y **Glucemia en ayunas (bgr)**.

Tabla 1: Comparativa de intervalos de confianza tradicionales y por métodos de remuestreo Bootstrap.

Variable Clínica	Tamaño Muestra l (n)	Media Muestra l ($\bar{x}$)	IC Clásico (95%)	IC Percentil (95%)	IC BCa (95%)
Edad (age)	388	51.46 años	[49.75, 53.16]	[49.72, 53.12]	[49.71, 53.11]
Presión Arterial (bp)	385	76.47 mmHg	[75.10, 77.84]	[75.14, 77.85]	[75.17, 77.92]
Glucemia en Ayunas (bgr)	354	147.86 mg/dL	[139.61, 156.12]	[139.84, 156.56]	[140.26, 157.02]




Figura 1: Distribuciones muestrales bootstrap ($B = 10,000$) con intervalos de confianza clásicos, percentiles y BCa para Edad (age), Presión Arterial (bp) y Glucemia en Ayunas (bgr)

Al inspeccionar los histogramas de la distribución bootstrap:

- Edad y Presión Arterial:** Los gráficos muestran una forma acampanada y perfectamente simétrica. Debido a que el tamaño de la muestra es lo suficientemente grande ($n > 380$), el Teorema del Límite Central se cumple a cabalidad. Las líneas verticales que representan los intervalos Clásico, Percentil y BCa están prácticamente superpuestas. Los supuestos de normalidad del método clásico son válidos y altamente confiables.
- Glucemia (bgr):** La distribución empírica original presenta una fuerte asimetría hacia la derecha (cola larga de pacientes con crisis hiperglucémicas). En el gráfico fig_bootstrap_bgr.png, la distribución de las medias remuestreadas retiene una leve asimetría. Aquí se observa una clara **discrepancia**: el IC BCa se desplaza hacia la derecha ([140.26,157.02]) en comparación con el clásico. El método BCa es el único confiable en este escenario porque corrige estadísticamente el sesgo mediano (z_0) y la aceleración (a) provocada por los pacientes con valores extremos, demostrando que el IC clásico subestimaba el límite superior del riesgo.

2. Validación de pruebas de hipótesis mediante permutación:

Se seleccionó para su validación la prueba de hipótesis de comparación de medias para muestras independientes de S1: Edad de los pacientes con Enfermedad Renal Crónica (CKD) vs. Pacientes Sanos (No CKD).




Figura 2: Distribución de la hipótesis nula obtenida mediante el test de permutación (10,000 iteraciones) para la diferencia de edades entre pacientes con CKD y No CKD, contrastada con la diferencia real observada.

El gráfico de la prueba de permutación muestra un histograma centrado en 0.0, el cual representa la distribución de la hipótesis nula (donde la etiqueta de tener o no enfermedad renal se baraja aleatoriamente y no influye en la edad). La línea roja vertical, que denota la diferencia real observada de 8.30 años, se ubica completamente fuera del soporte del histograma, en el extremo absoluto de la cola derecha. Al no encontrarse una sola permutación aleatoria entre las 10,000 que iguale o supere el valor observado, el p-valor empírico confirma una concordancia absoluta con el enfoque paramétrico. Esto demuestra de forma exacta y libre de supuestos distribucionales que la edad es una variable significativamente asociada al desarrollo de la patología renal.

3. Evaluación de estabilidad de correlaciones:

Se analizó la sensibilidad y estabilidad estructural de las relaciones lineales más críticas identificadas en S1 mediante el cálculo de intervalos de confianza por bootstrap no paramétrico al 95%.




Figura 3: Intervalos de confianza bootstrap al 95% para evaluar la estabilidad de las correlaciones clínicas críticas de Creatinina vs. Urea en Sangre (antes y después del filtrado de outliers) y Hemoglobina vs. Volumen Globular Aglomerado

El gráfico comparativo de los intervalos de confianza revela lo siguiente:

- **Correlación Robusta (hemo vs. pcv):** Su IC bootstrap es extremadamente estrecho y concentrado cerca de 0.90. Esto demuestra que la relación biológica entre la concentración de hemoglobina y el volumen de glóbulos rojos es una estructura matemática sumamente estable y un predictor seguro, siempre y cuando se limpien los errores informáticos de tipeo (como el código 999).
- **Correlación Inestable (sc vs. bu):** El IC bootstrap original para la muestra total es excesivamente amplio debido a que unos pocos pacientes en estado crítico (valores masivos de creatinina por falla renal aguda) actúan como puntos de alto apalancamiento. Al remover estos valores atípicos, el gráfico muestra cómo el intervalo no solo se estrecha, sino que el coeficiente se desplaza de 0.58 a un robusto 0.71. La relación en rangos moderados es lineal, pero se vuelve inestable en los extremos.

4. Simulación Monte Carlo basada en parámetros de S1:

Se implementó una simulación de Monte Carlo con 10,000 iteraciones para proyectar el comportamiento conjunto de las variables del paciente utilizando la matriz de covarianza y los promedios paramétricos estimados en S1 ($\mu_{edad} = 51.46$, $\mu_{bp} = 76.47$, $\mu_{bgr} = 147.86$).




Figura 4: Evaluación de la convergencia para la simulación Monte Carlo (10,000 iteraciones), mostrando la estabilización de la media acumulada de las variables clínicas sintéticas a medida que aumenta el número de réplicas

1. **Evaluación de Convergencia:** El gráfico de convergencia muestra el comportamiento de la media simulada acumulada a lo largo de las iteraciones. Se observa una fuerte oscilación estocástica inicial durante las primeras 1,500 iteraciones. Sin embargo, a partir de las 4,500 iteraciones, la línea se estabiliza por completo en un comportamiento asintótico horizontal, garantizando que el tamaño de 10,000 corridas fue matemáticamente suficiente para neutralizar el error de muestreo y estabilizar los resultados.
2. **Interpretación del Fenómeno Real:** Al simular los escenarios médicos, el modelo refleja de forma probabilística cómo el descontrol metabólico de la glucemia (promedio simulado de 147.86 mg/dL, correspondiente a rangos diabéticos) coexiste con alteraciones en la presión arterial. La simulación permite estimar la probabilidad conjunta de que un paciente caiga en "zona de crisis", sirviendo como herramienta de simulación de riesgo clínico para la toma de decisiones preventivas en salud pública.




Figura 5: Análisis de robustez y detección de observaciones influyentes mediante estimación Jackknife, ilustrando el impacto de la eliminación secuencial de casos sobre los coeficientes de correlación y la estabilidad de los parámetros de S1.

5. Análisis de robustez:

Se evaluó el impacto de las suposiciones y los datos atípicos combinando las técnicas de remuestreo (Bootstrap/Jackknife) y las técnicas de filtrado de datos aplicadas en el notebook.

- **Conclusiones Altamente Sensibles (Requieren Cautela):** Los análisis que involucran variables con distribuciones de colas pesadas como la Creatinina (sc), Urea (bu) y Glucemia (bgr). Los modelos estadísticos basados en la normalidad (como las regresiones lineales clásicas) fallarán o entregarán parámetros sesgados si no se realiza un filtrado previo de outliers o una transformación matemática (por ejemplo, logarítmica), ya que el remuestreo demostró que un grupo minoritario de pacientes graves arrastra de forma desproporcionada los estadísticos muestrales.
- **Conclusiones Robustas (Confiables):** Las estimaciones de la Edad y la Presión Arterial, así como la diferencia de edades entre pacientes enfermos y sanos. Al aplicar remuestreos e intercambios de etiquetas, los resultados se mantuvieron estables, lo que significa que el tamaño de la muestra es lo suficientemente grande como para blindar estas conclusiones frente a la presencia de cualquier observación individual influyente.

6. Preparación para la Sumativa 3:

A continuación, se presentan las directrices críticas y recomendaciones metodológicas orientadas al desarrollo de los modelos de Machine Learning para la **Sumativa 3 (S3)**.

Tabla 2: Directrices críticas y recomendaciones metodológicas para el desarrollo de modelos en la Sumativa 3 (S3).

Componente del Proyecto (S3)	Directriz Crítica / Recomendación Metodológica	Impacto en el Modelo y Justificación
Parámetros Consolidados	Utilizar los intervalos de confianza corregidos por el método BCa como la línea base para caracterizar el riesgo poblacional.	Mitiga el sesgo mediano y los problemas de aceleración provocados por variables de química sanguínea asimétricas (como la glucemia bgr).
Tratamiento de Correlaciones y Redundancia	Excluir una de las dos variables (hemo o pcv) o, en su defecto, implementar técnicas de regularización (Ridge/Lasso) .	Evita problemas severos de multicolinealidad que desestabilizan y distorsionan los coeficientes del modelo, dado que su correlación lineal se validó como sumamente alta e idéntica ($r = +0.895$).
Higiene del Pipeline de Datos	Programar una función de limpieza automatizada al inicio del flujo para interceptar y remover códigos de error informáticos (como el valor "999" en el volumen globular).	Previene la contaminación de las métricas distributivas y asegura que los algoritmos de aprendizaje no interpreten códigos de error como valores clínicos reales.
Gestión de Outliers Biológicos	Aislar y tratar de forma diferenciada mediante algoritmos robustos (o transformaciones matemáticas) los valores extremos de insuficiencia renal severa ($sc > 5$ y $bu > 150$).	Evita que un grupo minoritario de pacientes críticos actúe como puntos de alto apalancamiento, sesgando las predicciones generales para el grueso de la población con daño moderado o sano.

7. Bibliografía (APA 7)

- Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association*, 82(397), 171-185.
<https://doi.org/10.1080/01621459.1987.10478410>
- Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.
- Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.^a ed.). Springer.